

Автоматизация анализа архивных геолого-геофизических отчётов с применением больших языковых моделей

Р.Р. Киямов¹, [соавтор]¹

1 – [организация]

E-mail: [e-mail]

Телефон: [телефон]

Аннотация

Значительная часть геологической информации по изученным районам хранится в фондовых отчётах в виде сканированных документов: тексты, таблицы, структурные карты и разрезы недоступны для программной обработки. В работе предложена архитектура автоматизации анализа таких материалов на основе связки классических алгоритмов компьютерного зрения и оптического распознавания (OCR) с большими языковыми моделями (LLM). Ключевой принцип: LLM не заменяет вычислительные методы, а выполняет функции, ранее требовавшие участия эксперта, — исправление распознанного текста, классификацию объектов, перекрёстный контроль качества между текстом отчёта и графическими приложениями. Подход апробирован на отчёте сейсморазведочной партии 1980 г.: автоматически распознано оглавление графических приложений, на структурной карте выделено более 1000 текстовых объектов. Результаты экспортируются в открытые форматы GeoJSON/GeoPackage. Все компоненты допускают развёртывание на локальной инфраструктуре с открытыми весами моделей.

Ключевые слова

большие языковые модели, RAG, автоматизация, архивные отчёты, OCR, компьютерное зрение, структурные карты, GeoPackage

Фонды геологической информации содержат десятки тысяч отчётов о геологоразведочных работах прошлых десятилетий. Для территорий с высокой степенью изученности эти материалы нередко являются единственным источником сведений о строении разреза, однако существуют только в виде сканов: поиск ведётся вручную, а количественные данные (отметки горизонтов, результаты испытаний, параметры съёмки) повторно оцифровываются при каждом обращении. Развитие больших языковых и мультимодальных моделей делает автоматизацию работы с такими документами практически достижимой.

Прямое применение языковых моделей к сканам карт показывает низкую точность локализации объектов, а классические системы векторизации, напротив, не справляются с семантикой: разрывы линий на подписях, наложение объектов, рукописные чертёжные шрифты. Предлагаемое решение разделяет функции (рисунок 1): детерминированные алгоритмы отвечают на вопрос «где» (детекция текстовых областей, линий, засечек средствами OpenCV), языковые модели — на вопрос «что» (чтение вырезанных фрагментов, классификация, исправление ошибок OCR по контексту), а правила и статистика листа выполняют контроль качества.




Рисунок 1 – Архитектура системы автоматизации

Обработка отчёта начинается с оглавления графических приложений. OCR-модель (PaddleOCR) извлекает текстовые блоки и структуру таблицы (рисунок 2): номера приложений, наименования, гриф, привязка к томам восстанавливаются программно [1]. Характерные ошибки распознавания машинописи — замены I/1 и O/0, пропуски символов в местах дефектов бумаги — исправляются языковой моделью по контексту строки, после чего агент-маршрутизатор типизирует приложения (карта, схема, разрез, таблица) и направляет каждый лист в профильный модуль обработки. Так, для апробируемого отчёта система автоматически определила лист структурной карты и схему расположения профилей.

№ п/п	Наименование	К-во лист.	Гриф секретности	Примечание
1	Вертикальный годограф, графики пластовых и средних скоростей. Сигдакская скважина Р-10.	1	несекретно	Том I
2	Временной разрез. Профиль 91501. ОТ E12	1	несекретно	Том I
3	Временной разрез. Профиль 91501	1	несекретно	Том II
4	Временной разрез. Профиль 91503. ОТ E12	1	несекретно	Том II
5	Временной разрез. Профиль 91503	1	несекретно	Том II
6	Временной разрез. Профиль 91504. ОТ E12	1	несекретно	Том II
7	Временной разрез. Профиль 91504	1	несекретно	Том II
8	Временной разрез. Профиль 91508. ОТ E12	1	несекретно	Том II
9	Временной разрез. Профиль 91508	1	несекретно	Том II
10	Фрагмент временного разреза ОНП. Профиль 91508	1	несекретно	Том II
11	Временной разрез. Профиль 91509. ОТ E12	1	несекретно	Том II
12	Временной разрез. Профиль 91509	1	несекретно	Том II
13	Схема сейсмогеологических условий района работ Хампинской партии	1	несекретно	Том II
14	Сопоставление кривой средней скорости Сигдакской скважины Р-10 с графиками	1	несекретно	Том II
15	Сейсмический разрез. Профиль 91501	1	несекретно	Том II
16	Сейсмический разрез. Профиль 91503	1	несекретно	Том II
17	Сейсмический разрез. Профиль 91504	1	несекретно	Том II
18	Сейсмический разрез. Профиль 91508	1	несекретно	Том II
19	Сейсмический разрез. Профиль 91509	1	несекретно	Том II
20	Карта изохрон То набл. отраженной волны К. Хампинская площадь. М 1:200000	1	несекретно	Том II
21	Структурная карта по отражающему горизонту К. Хампинская площадь. М 1:200000	1	несекретно	Том II
22	Карта изохрон То прив (+1.5) отраженной волны К. Шейнская площадь. М 1:100000	1	несекретно	Том II

Наименование	К-во лист.	Гриф секретности	Примечание
Вертикальный годограф, графики пластовых и средних скоростей. Сигдакская скважина Р-10.	1	несекретно	Том I
Временной разрез. Профиль 91501. ОТ E12	1	несекретно	Том I
Временной разрез. Профиль 91501	1	несекретно	Том II
Временной разрез. Профиль 91503. ОТ E12	1	несекретно	Том II
Временной разрез. Профиль 91503	1	несекретно	Том II
Временной разрез. Профиль 91504. ОТ E12	1	несекретно	Том II
Временной разрез. Профиль 91504	1	несекретно	Том II
Временной разрез. Профиль 91508. ОТ E12	1	несекретно	Том II
Временной разрез. Профиль 91508	1	несекретно	Том II
Фрагмент временного разреза ОНП. Профиль 91508	1	несекретно	Том II
Временной разрез. Профиль 91509. ОТ E12	1	несекретно	Том II
Временной разрез. Профиль 91509	1	несекретно	Том II
Схема сейсмогеологических условий района работ Хампинской партии	1	несекретно	Том II
Сопоставление кривой средней скорости Сигдакской скважины Р-10 с графиками	1	несекретно	Том II
Сейсмический разрез. Профиль 91501	1	несекретно	Том II
Сейсмический разрез. Профиль 91503	1	несекретно	Том II
Сейсмический разрез. Профиль 91504	1	несекретно	Том II
Сейсмический разрез. Профиль 91508	1	несекретно	Том II
Сейсмический разрез. Профиль 91509	1	несекретно	Том II
Карта изохрон То набл. отраженной волны К. Хампинская площадь. М 1:200000	1	несекретно	Том II
Структурная карта по отражающему горизонту К. Хампинская площадь. М 1:200000	1	несекретно	Том II
Карта изохрон То прив (+1.5) отраженной волны К. Шейнская площадь. М 1:100000	1	несекретно	Том II

Рисунок 2 – Распознавание оглавления графических приложений: слева — скан с детекцией текстовых областей, справа — восстановленная структура таблицы

Тексты отчёта индексируются в базе знаний с гибридным поиском и моделью переранжирования (retrieval-augmented generation); это обеспечивает ответы на вопросы по содержанию отчёта со ссылками на страницы и используется модулем контроля качества как источник эталонных сведений: число и названия структур, глубины горизонтов, параметры съёмки [2].

Для графических приложений применяется трёхуровневая схема. По статистике листа (распределению высот символов) выделяются текстовые области разных классов шрифта; на апробируемой структурной карте выделено 1088 объектов (рисунок 3). Мультиформальная модель читает вырезанные фрагменты, классификация выполняется по формату значения: отметки пикетов, подписи изогипс, номера сейсмопрофилей, скважины. Контроль качества сопоставляет извлечённые значения с сечением изогипс и данными текста отчёта; каждое замечание снабжается доказательством — страницей и фрагментом изображения.

Automation of archival geological and geophysical report analysis using large language models

R.R. Kiamov¹, [co-author]¹

1 – [organization]

E-mail: [e-mail]

Phone number: [phone]

Abstract

A significant part of geological information for well-studied regions is stored in archival reports as scanned documents: texts, tables, structural maps and sections are inaccessible to software processing. This paper proposes an architecture for automating the analysis of such materials based on a combination of classical computer vision and optical character recognition (OCR) algorithms with large language models (LLM). The key principle is that the LLM does not replace computational methods but performs functions that previously required an expert: correcting recognized text, classifying objects, and cross-checking quality between the report text and graphical appendices. The approach was tested on a 1980 seismic survey report: the table of contents of graphical appendices was recognized automatically, and more than 1000 text objects were detected on the structural map. The results are exported to open GeoJSON/GeoPackage formats. All components can be deployed on local infrastructure using open-weight models.

Keywords

large language models, RAG, automation, archival reports, OCR, computer vision, structural maps, GeoPackage

Geological information archives contain tens of thousands of exploration reports from past decades. For well-studied territories, these materials are often the only source of information about the subsurface structure, yet they exist only as scans: search is performed manually, and quantitative data (horizon depths, test results, survey parameters) are re-digitized at each use. The development of large language and multimodal models makes the automation of such document processing practically achievable.

Direct application of language models to map scans shows low object localization accuracy, while classical vectorization systems, on the contrary, fail at semantics: line breaks at labels, overlapping objects, handwritten drafting fonts. The proposed solution separates the functions (Figure 1): deterministic algorithms answer the question "where" (detection of text regions, lines and tick marks using OpenCV), language models answer the question "what" (reading cropped fragments, classification, context-based correction of OCR errors), while rules and sheet statistics perform quality control.

Report processing starts with the table of contents of graphical appendices. The OCR model (PaddleOCR) extracts text blocks and the table structure (Figure 2): appendix numbers, titles, classification labels and volume references are reconstructed programmatically [1]. Typical typewriting recognition errors — I/1 and O/0 substitutions, missing characters at paper defects — are corrected by the language model using the line context, after which a routing agent classifies the appendices (map, scheme, section, table) and sends each sheet to the corresponding processing module.

Report texts are indexed in a knowledge base with hybrid search and a reranking model (retrieval-augmented generation); this provides answers to questions about the report content with page references and serves the quality control module as a source of reference information: the number and names of structures, horizon depths, survey parameters [2].

A three-level scheme is applied to graphical appendices. Text regions of different font classes are detected using sheet statistics (character height distribution); 1088 objects were detected on the studied structural map (Figure 3). A multimodal model reads the cropped fragments, and classification is performed by value format: picket depth marks, isoline labels, seismic profile numbers, wells. Quality control compares the extracted values with the isoline interval and the report text data; each issue is accompanied by evidence — a page and an image fragment.

The extraction results are exported to GeoJSON/GeoPackage and loaded into GIS and interpretation software [3]. Since archival materials generally cannot be transferred to external cloud services, all system components — OCR, language and multimodal models, the knowledge base — are deployed on local infrastructure using open-weight models.

The proposed architecture is incremental: each module — report text search, tabular data extraction, map processing — has independent practical value and measurable quality metrics. This allows gradual adoption: from a report knowledge base to full digitization of graphical appendices with automatic quality control.

References

1. Li C., Liu W., Guo R. et al. PP-OCRv3: More Attempts for the Improvement of Ultra Lightweight OCR System // arXiv:2206.03001. 2022.
2. Lewis P., Perez E., Piktus A. et al. Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks // Advances in Neural Information Processing Systems. 2020. Vol. 33. P. 9459–9474.
3. OGC GeoPackage Encoding Standard. Version 1.4.0. Open Geospatial Consortium, 2024.